ISPC
INSTITUTO SUPERIOR POLITÉCNICO CÓRDOBA

Dirección General de EDUCACIÓN TÉCNICA Y FORMACIÓN PROFESIONAL

Ministerio de EDUCACIÓN

CÓRDOBA Seguimos haciendo

TRABAJO PRÁCTICO INTEGRADOR EJE N°1

TÉCNICAS DE PROCESAMIENTO DEL HABLA - TSCDIA.

FUNDAMENTOS Y PROCESAMIENTO DIGITAL DE LA SEÑAL

Carrera: Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial - TSCDIA.

Materia: Técnicas de Procesamiento del Habla.

Docente: Rubén Emmanuel Giudice Bojanich.

Integrantes:
- Maciel Barbero
- Jonathan Molina
- Mauricio Molina

Abril 2026

PARTE 1: FUNDAMENTOS TEÓRICOS

Pregunta 1.1: Muestreo y Teorema de Nyquist

a) ¿Qué es el muestreo y por qué es necesario digitalizar una señal de audio?
El muestreo consiste en representar una señal analógica mediante mediciones tomadas a intervalos regulares de tiempo, transformando una señal continua en una secuencia discreta de valores.

La digitalización es necesaria porque las señales del mundo físico son continuas, mientras que los sistemas computacionales solo pueden procesar información discreta representada numéricamente. Por este motivo, toda señal analógica debe ser convertida a formato digital para su análisis y procesamiento.

b) Una señal de voz tiene componentes de frecuencia hasta 4000 Hz.

- **¿Cuál es la frecuencia de muestreo mínima teórica necesaria?**
- **Si muestreamos a 6000 Hz, ¿qué problema podríamos tener?**
- **¿Por qué el audio de teléfono usa 8000 Hz?**

  - **Frecuencia mínima:** De acuerdo con el Teorema de Nyquist-Shannon, la frecuencia de muestreo debe ser al menos el doble de la frecuencia máxima de la señal.
    Por lo tanto, la frecuencia mínima requerida es 8000 Hz.

  - **Problema a 6000 Hz:** Se produce aliasing, ya que la frecuencia de muestreo es insuficiente. Esto provoca que componentes de alta frecuencia se representen de forma incorrecta como frecuencias más bajas, generando distorsión en la señal.

  - **Audio de teléfono:** La voz humana contiene la mayor parte de su información relevante por debajo de los 4000 Hz. Una frecuencia de muestreo de 8000 Hz permite capturar adecuadamente este rango cumpliendo el criterio de Nyquist.

- **c) Investigá: ¿por qué el audio de CD usa 44100 Hz y no 40000 Hz exactamente?**
  El oído humano puede percibir frecuencias de hasta aproximadamente 20.000 Hz. Según el criterio de Nyquist, sería necesario un mínimo de 40.000 Hz para su representación.

  El estándar de CD utiliza 44.100 Hz porque incorpora un margen adicional que facilita la implementación de filtros anti-aliasing antes del muestreo, reduciendo la posibilidad de distorsión en la señal digitalizada.

Pregunta 1.2: Cuantización y Resolución

a) Compará dos grabaciones de la misma señal:

- **Grabación A (8 bits) Grabación B (16 bits).**

  ¿Cuántos niveles de amplitud tiene cada una?
  ¿Cuál tendrá mejor calidad y por qué?
  ¿Qué desventaja tiene la grabación B?

  Niveles de amplitud:

  - 8 bits → 256 niveles
  - 16 bits → 65.536 niveles

  Calidad: La codificación de 16 bits ofrece mayor precisión en la representación de la señal, ya que reduce el error de cuantización y permite una aproximación más fiel de la señal original.

  Desventaja: El uso de 16 bits implica un mayor tamaño de archivo y un mayor requerimiento de almacenamiento y procesamiento.

- **b) Si una señal tiene un rango dinámico de 96 dB, ¿cuántos bits mínimos se necesitan para representarla sin perder información? (Pista: cada bit aporta ~6 dB)**
  Cada bit proporciona aproximadamente 6 dB de rango dinámico.

  Por lo tanto:
  96 dB ÷ 6 dB ≈ 16 bits

  Se requieren aproximadamente 16 bits para representar la señal sin pérdida significativa de información.

Pregunta 1.3: Aliasing

- **a) Describí el fenómeno de aliasing con un ejemplo cotidiano.**
  El aliasing es un error que ocurre cuando una señal se muestrea a una frecuencia insuficiente. Como resultado, las frecuencias altas se "pliegan" y aparecen como frecuencias más bajas incorrectas.

  Un ejemplo cotidiano es el efecto de las ruedas en películas: cuando giran muy rápido, parecen hacerlo en sentido contrario debido a la velocidad de captura de la cámara.

- **b) Matemáticamente:**
  Señal original 7000 Hz,
  Frecuencia de muestreo 8000 Hz.
  ¿Qué frecuencia "falsa" aparecerá después del muestreo?
  La frecuencia de Nyquist es:
  8000 / 2 = 4000 Hz

  Como la señal supera este límite, se produce aliasing.
  La frecuencia observada será:

  8000 - 7000 = 1000 Hz

  Por lo tanto, la frecuencia falsa que aparece es 1000 Hz.

- **c) ¿Cómo se puede prevenir el aliasing? Mencioná al menos dos estrategias.**

  1. Aumentar la frecuencia de muestreo:
     Consiste en elegir una frecuencia de muestreo que sea al menos el doble de la frecuencia máxima de la señal ($f_s \geq 2 \cdot f_{max}$). De esta manera se cumple el criterio de Nyquist y se evita la superposición de frecuencias.

  2. Aplicar un filtro anti-aliasing (paso-bajo):
     Antes del muestreo, se utiliza un filtro paso-bajo que elimina las componentes de frecuencia superiores a la frecuencia de Nyquist ($f_s/2$). Esto evita que esas frecuencias altas generen distorsión en la señal digitalizada.

  Ambas estrategias suelen utilizarse en conjunto para garantizar una correcta digitalización de la señal.

Pregunta 1.4: Dominio del Tiempo vs. Frecuencia

- **a) Completá el cuadro comparativo:**

Característica	Dominio del Tiempo	Dominio de la Frecuencia
¿Qué muestra?	La variación de la amplitud de la señal en el tiempo	Las frecuencias que componen la señal y su magnitud/energía
Herramienta principal	Forma de onda (waveform)	FFT (Transformada Rápida de Fourier)
Ejemplo de uso	Detectar silencios, analizar duración o ritmo	Identificar tonos, armónicos o filtrar ruido

- **b) Explicá qué es la Transformada de Fourier y por qué es importante en el análisis de audio.**

  La Transformada de Fourier es una herramienta matemática que permite descomponer una señal en el dominio del tiempo en sus componentes de frecuencia. Es decir, transforma una señal compleja en una combinación de ondas senoidales más simples.

  Es fundamental en el análisis de audio porque en el dominio del tiempo las distintas frecuencias están mezcladas, lo que dificulta su interpretación. En cambio, en el dominio de la frecuencia se pueden identificar claramente los componentes del sonido, como tonos, armónicos o ruido, lo que permite analizar, procesar y extraer características relevantes para aplicaciones como el reconocimiento de voz.

- **c) Si ves un espectro con un pico muy alto en 440 Hz y picos más bajos en 880 Hz y 1320 Hz, ¿qué podés concluir sobre la señal?**

  Si en un espectro se observa un pico principal en 440 Hz y picos más pequeños en 880 Hz y 1320 Hz, se puede concluir lo siguiente:

  La frecuencia fundamental de la señal es 440 Hz, ya que es la componente con mayor energía.
  Los picos en 880 Hz y 1320 Hz corresponden a armónicos, ya que son múltiplos enteros de la frecuencia fundamental.
  Aunque estas frecuencias son más altas en valor (Hz), esto no implica mayor intensidad. La altura del pico en el espectro representa la energía asociada a cada frecuencia, no su valor numérico.
  Por este motivo, los armónicos suelen tener menor amplitud que la frecuencia fundamental, ya que aportan matices al sonido pero no dominan su energía principal.
  La presencia de estos armónicos indica que la señal no es un tono puro, sino un sonido complejo.
  Este patrón es característico de sonidos musicales y de la voz humana, donde el timbre depende de la distribución de armónicos.

PARTE 2: APLICACIÓN PRÁCTICA CON PYTHON

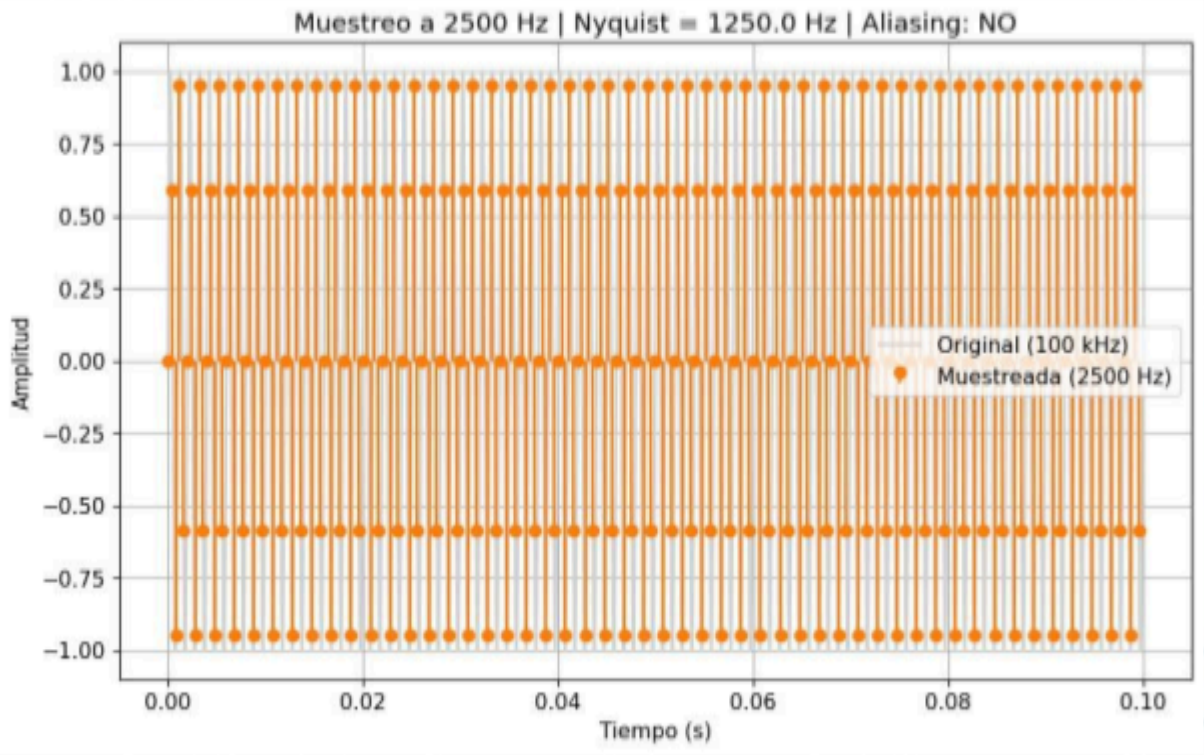

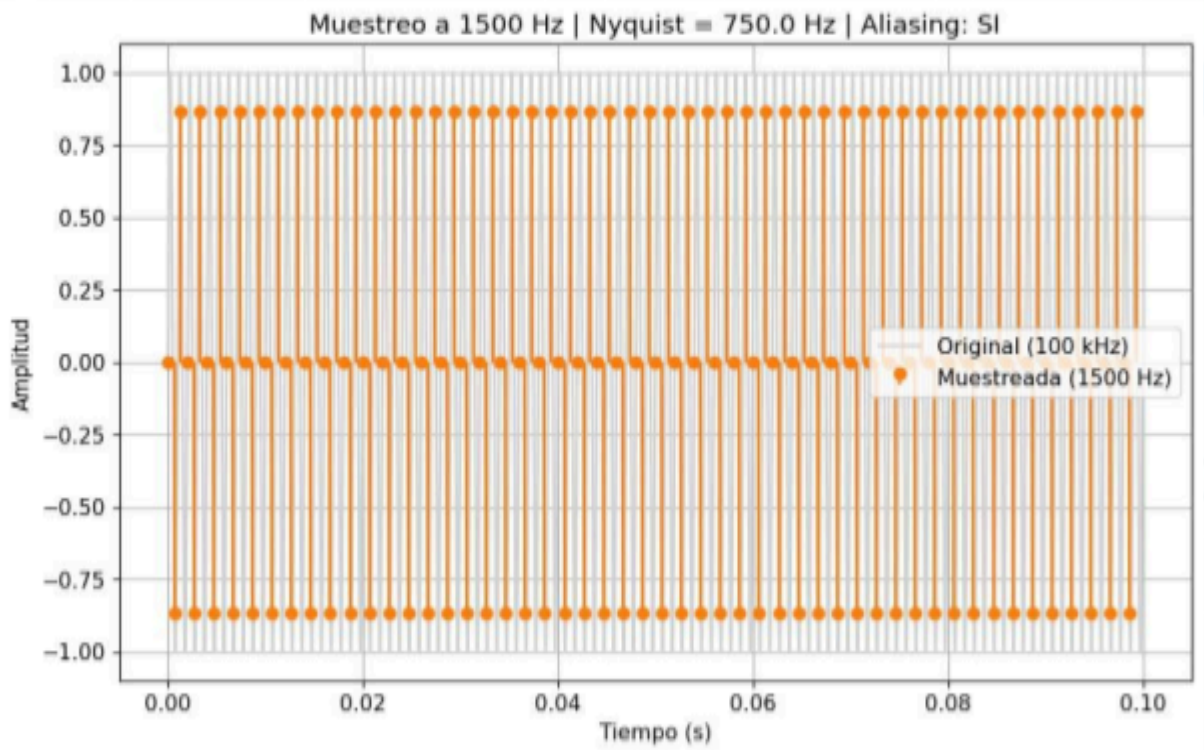

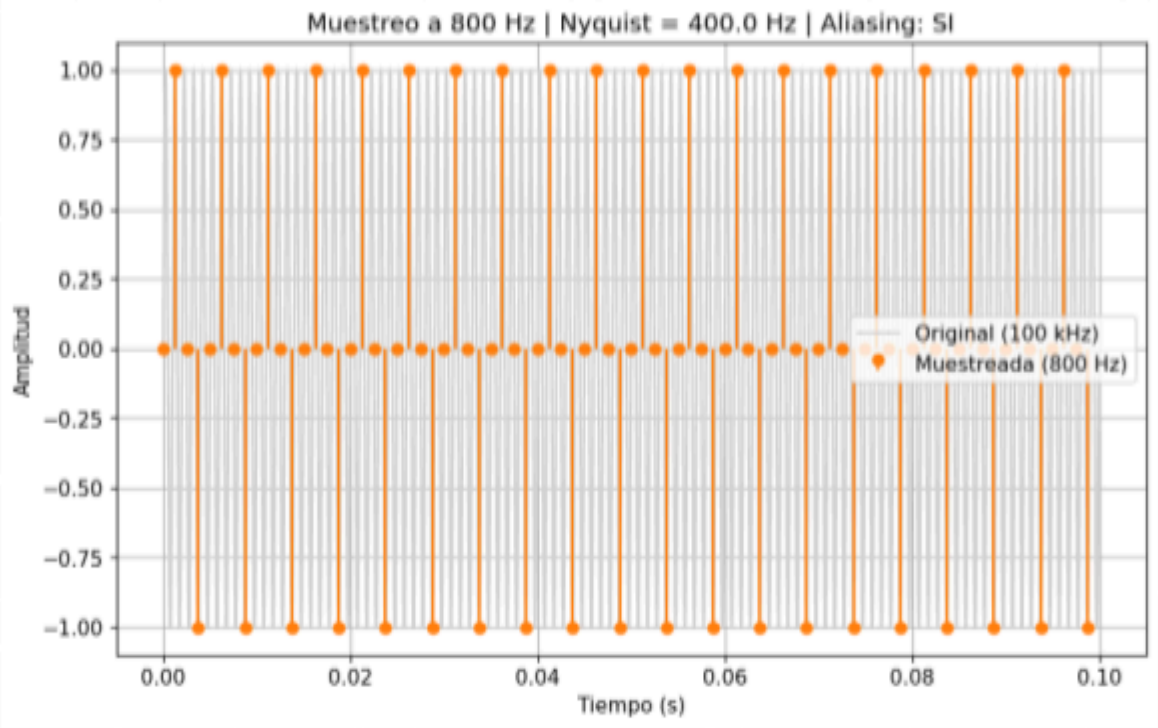

Conclusión sobre aliasing

1. Cuando se cumple Nyquist, la señal se representa correctamente Con fs = 2500 Hz, la señal de 1000 Hz se ve estable y conserva su forma original. Esto ocurre porque la frecuencia de muestreo es mayor al doble de la frecuencia de la señal (Nyquist se cumple).

2. Cerca del límite de Nyquist aparecen distorsiones Con fs = 1500 Hz, la señal empieza a deformarse. Aunque todavía se reconoce la forma general, ya no es una representación fiel. Esto indica que el sistema está en zona de riesgo de aliasing.

3. Cuando no se cumple Nyquist ocurre aliasing (caso crítico) Con fs = 800 Hz, la señal ya no representa correctamente la frecuencia original de 1000 Hz. En su lugar aparece una señal “falsa” de menor frecuencia (alias), completamente distinta a la original.

El aliasing no distorsiona la señal de forma visible únicamente, sino que reemplaza la frecuencia real por otra incorrecta, generando información engañosa.

Se observa que al reducir la frecuencia de muestreo por debajo del criterio de Nyquist, la señal pierde su representación original y aparecen componentes falsas (aliasing), lo que impide reconstruir correctamente la señal original.
Aliasing → afecta frecuencia/estructura temporal (formaglobal)
Cuantización → afecta amplitud (vertical)

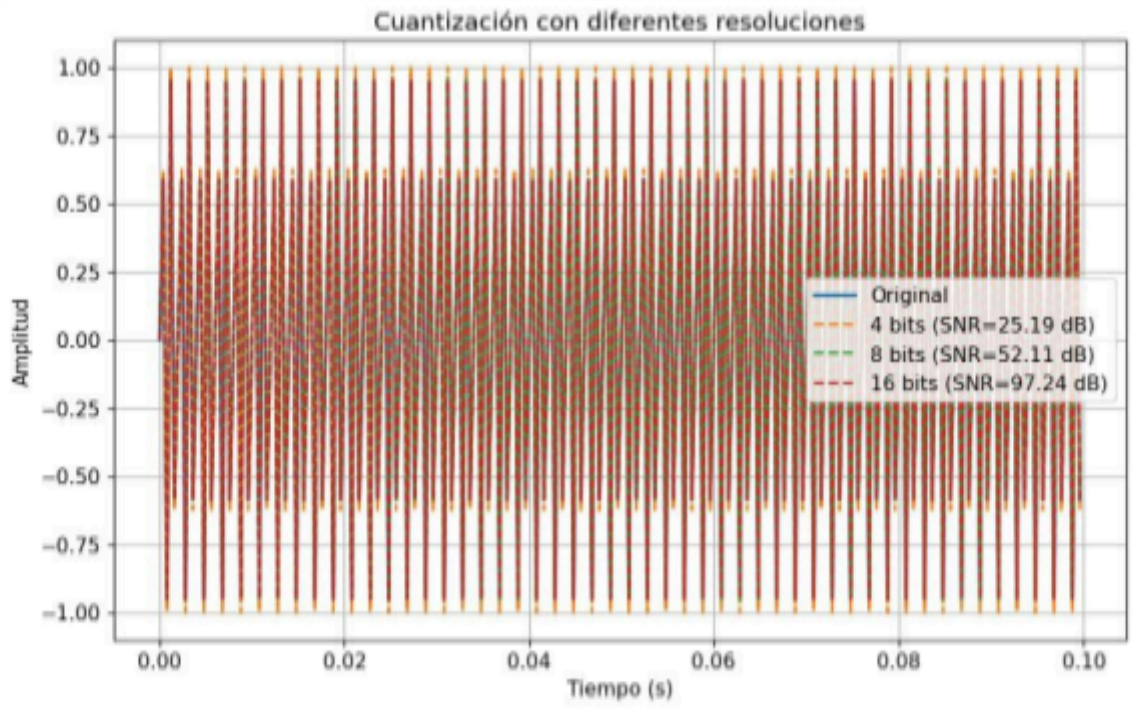

Conclusión sobre la cuantización

1. La cuantización introduce error desde pocos bits En 4 bits se observa una diferencia notable respecto a la señal original. La forma de onda deja de ser suave y empieza a verse “escalonada”, lo que indica un alto error de cuantización.

2. A mayor número de bits, menor es la distorsión En 8 bits la señal ya se parece bastante a la original, aunque todavía se nota cierta pérdida de precisión en los picos. En 16 bits la señal es prácticamente indistinguible de la original, lo que indica un error de cuantización muy bajo.

3. El número de bits controla la precisión de la representación Más bits implican más niveles de amplitud posibles, lo que permite representar mejor la señal continua original.

4. Existe una relación entre calidad y costo
   - 4 bits: baja calidad, fuerte distorsión, útil solo para análisis muy básico o señales muy simples
   - 8 bits: calidad media, ya usable pero con pérdida visible
   - 16 bits: alta fidelidad, estándar en audio de calidad

La cuantización no cambia la frecuencia de la señal, pero sí degrada su precisión en amplitud. Se observa que a mayor resolución en bits, menor es el error de cuantización y mayor la fidelidad respecto a la señal original, siendo 16 bits prácticamente indistinguible de la referencia.

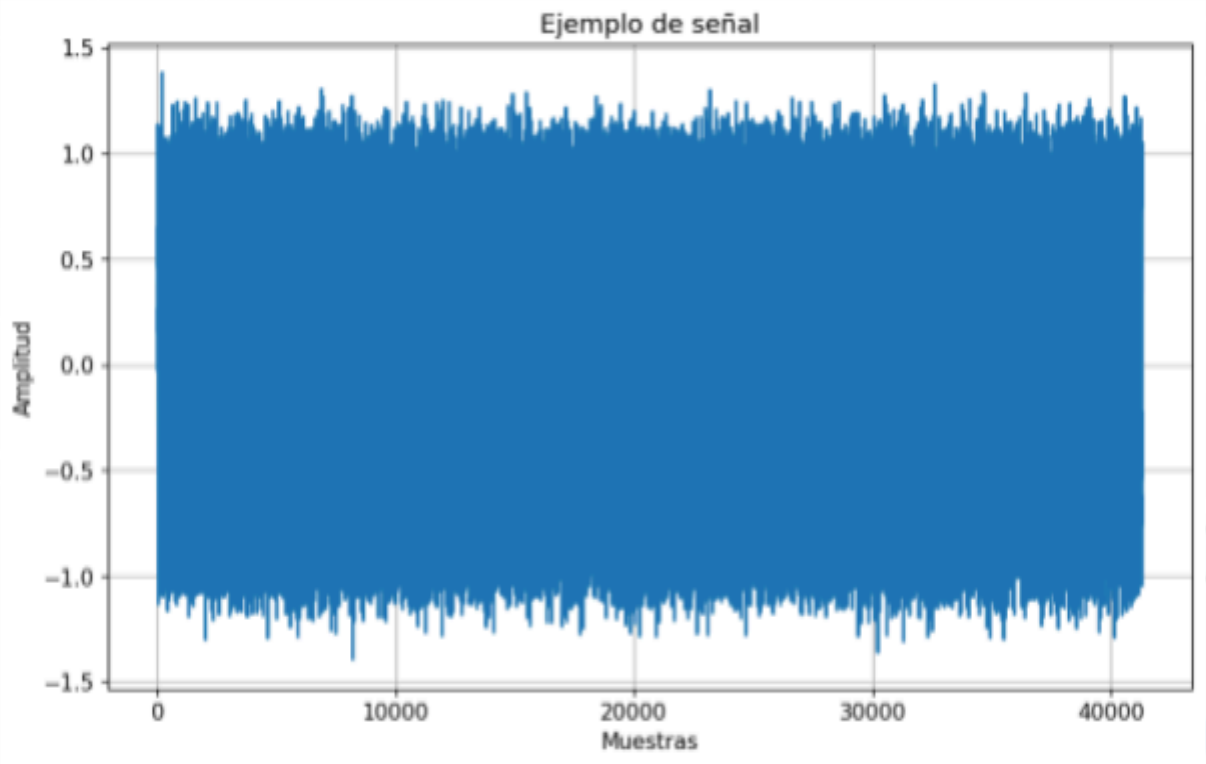
Ejemplo de señal
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5
Amplitud
0
10000
20000
30000
40000
Muestras

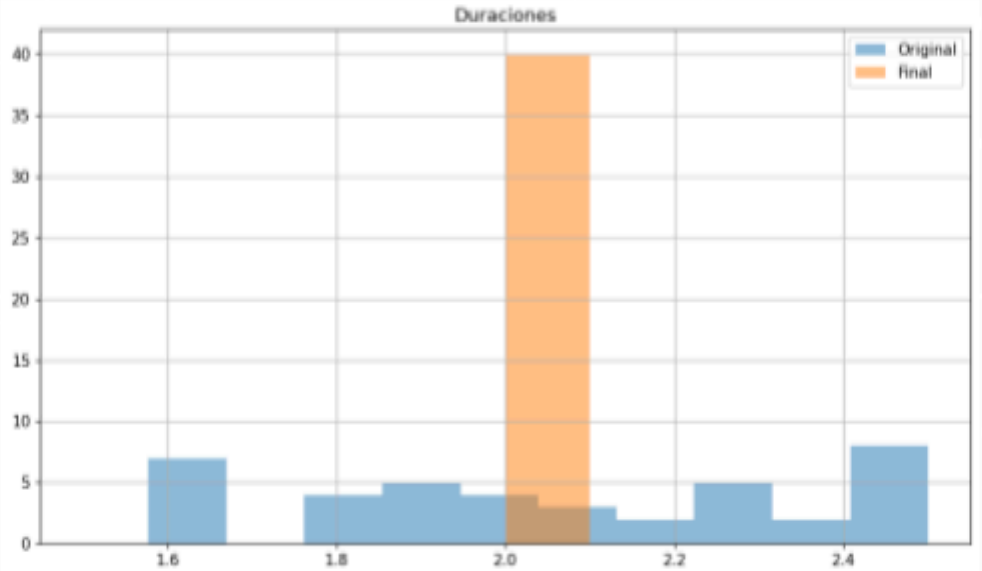
Duraciones
Original
Final
0
5
10
15
20
25
30
35
40
1.6
1.8
2.0
2.2
2.4

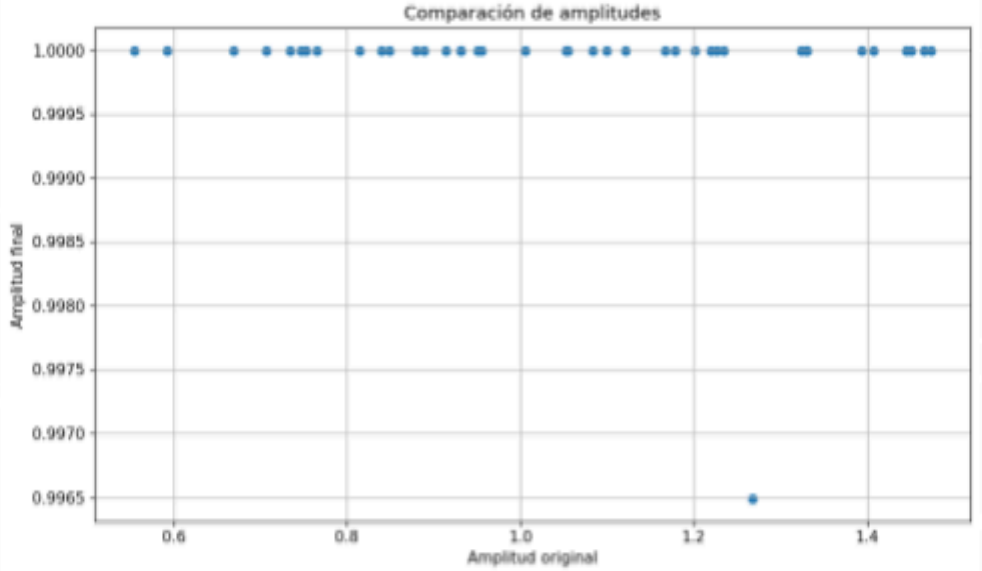
Comparación de amplitudes
Amplitud final
Amplitud original
1.0000
0.9995
0.9990
0.9985
0.9980
0.9975
0.9970
0.9965
0.6
0.8
1.0
1.2
1.4

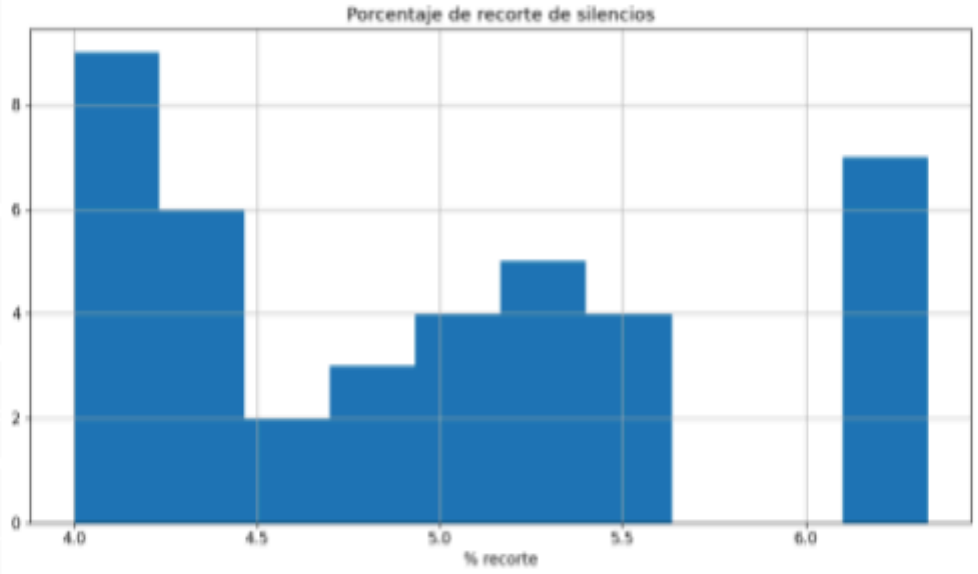
Porcentaje de recorte de silencios
% recorte
0
2
4
6
8
4.0
4.5
5.0
5.5
6.0

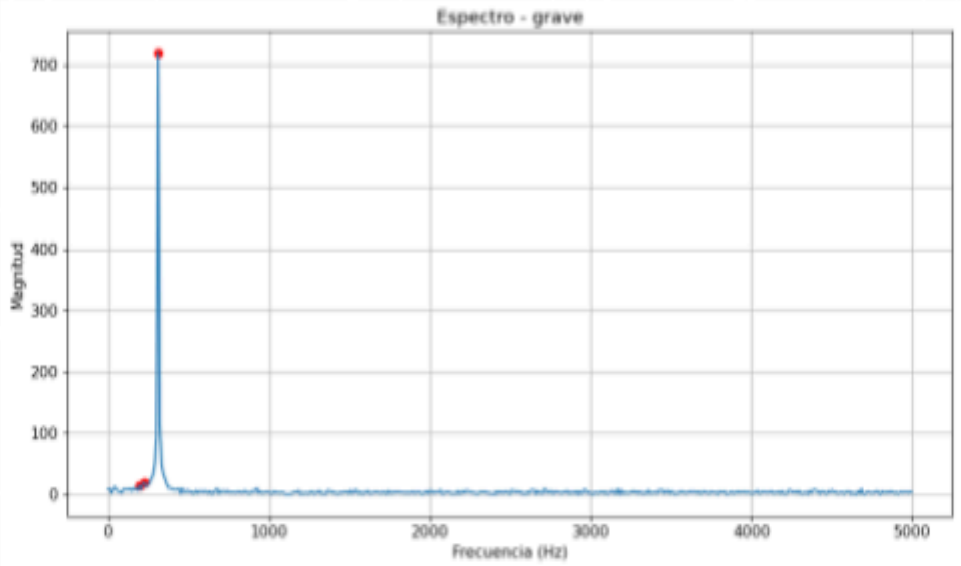
Espectro - grave
Magnitud
Frecuencia (Hz)
0
100
200
300
400
500
600
700
1000
2000
3000
4000
5000

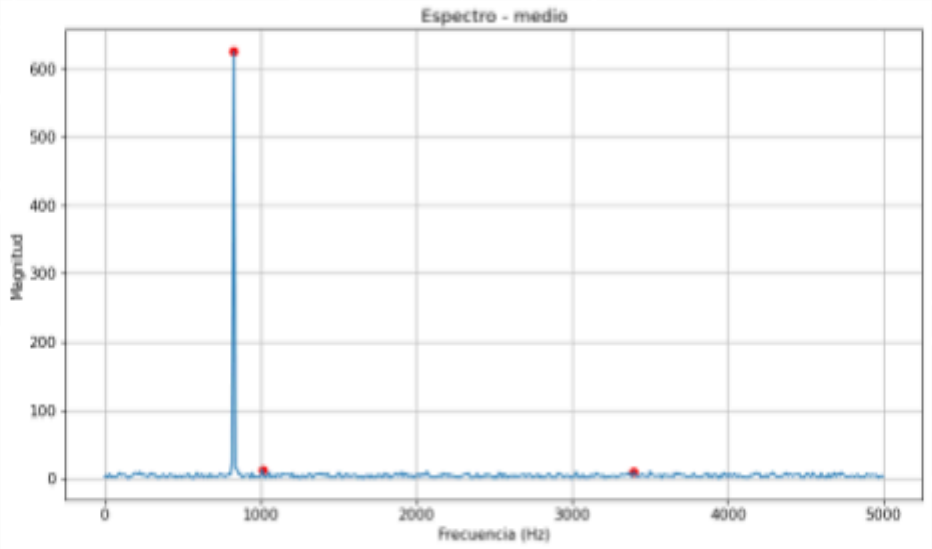
Espectro - medio
Magnitud
Frecuencia (Hz)
0
100
200
300
400
500
600
1000
2000
3000
4000
5000

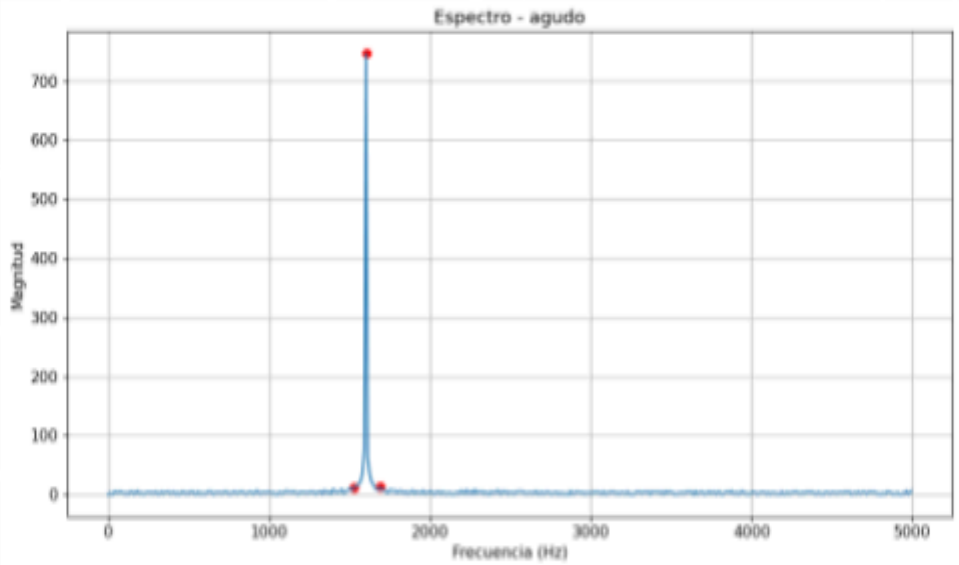
Espectro - agudo
Magnitud
Frecuencia (Hz)
0
100
200
300
400
500
600
700
1000
2000
3000
4000
5000

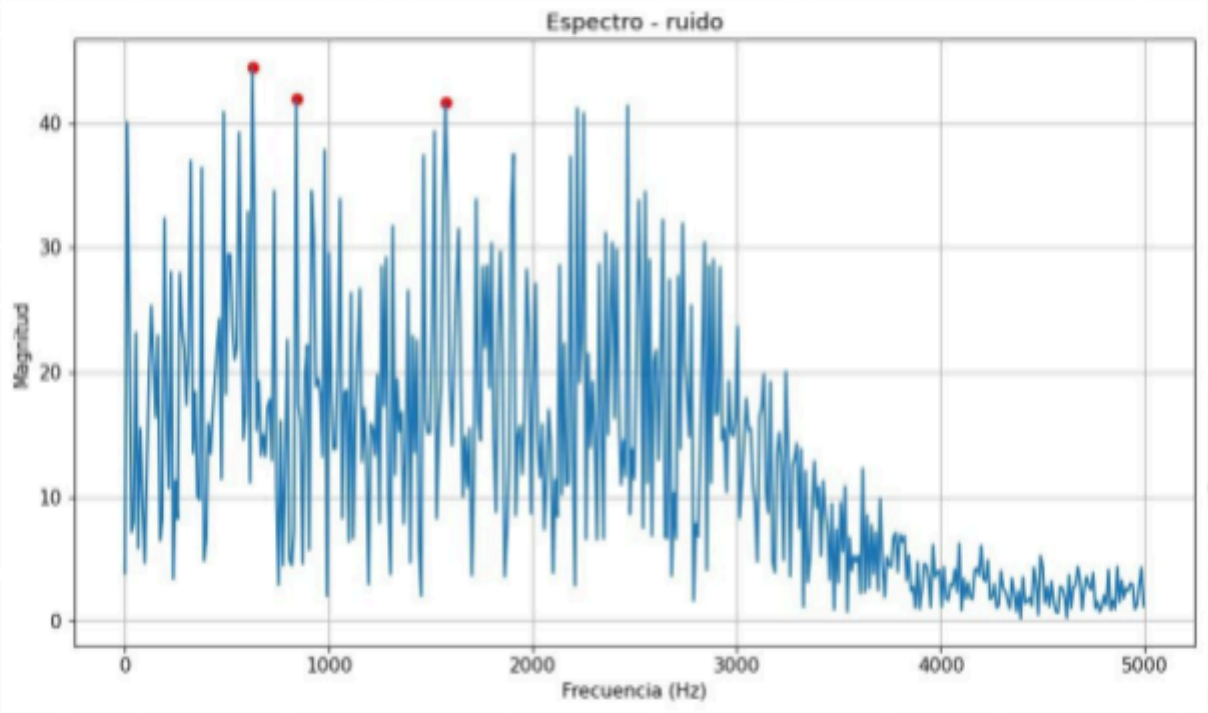
Espectro - ruido
Magnitud
Frecuencia (Hz)
0
10
20
30
40
0
1000
2000
3000
4000
5000

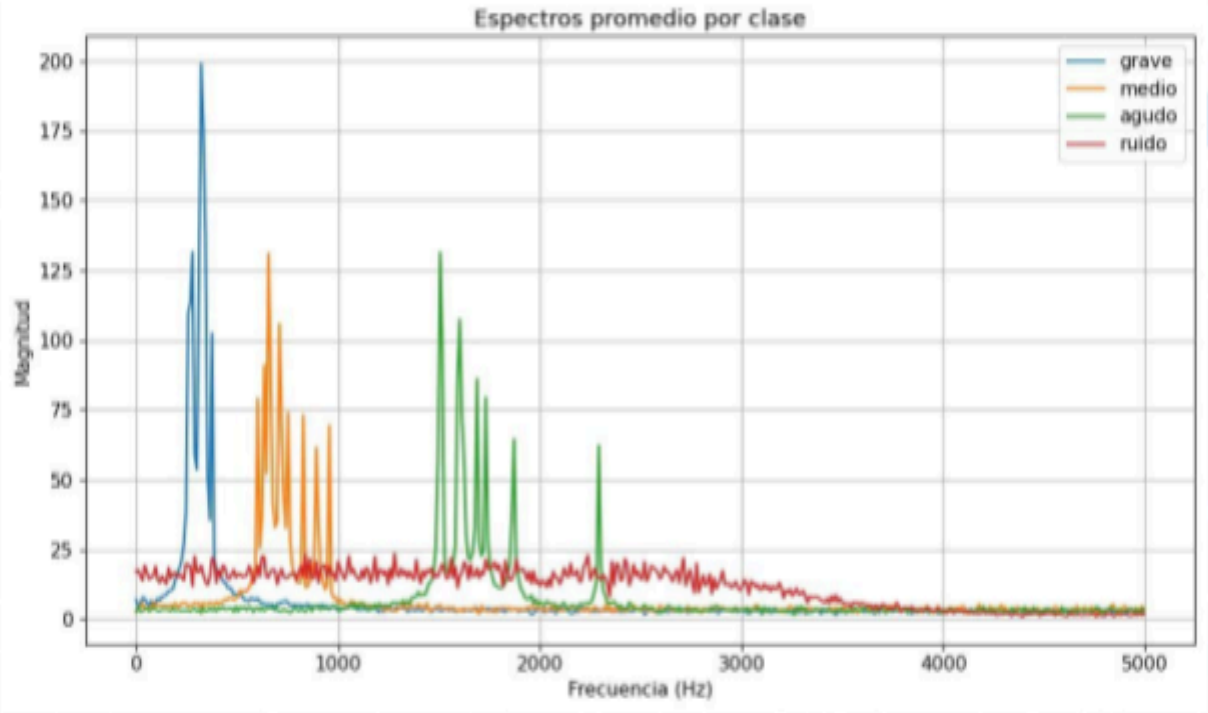
Espectros promedio por clase
grave
medio
agudo
ruido
Magnitud
Frecuencia (Hz)
0
25
50
75
100
125
150
175
200
0
1000
2000
3000
4000
5000

Respuestas - Análisis Espectral

¿Se pueden distinguir las clases solo mirando el espectro?

- Sí, las clases se pueden distinguir ya que cada una concentra energía en distintos rangos de frecuencia. Las señales graves, medias y agudas presentan picos bien definidos, mientras que el ruido es más uniforme.

¿Qué rangos de frecuencia son más discriminativos?

- Grave: aproximadamente 200 – 400 Hz
- Medio: aproximadamente 600 – 1000 Hz
- Agudo: aproximadamente 1500 – 2500 Hz
- Ruido: distribución amplia en todo el espectro

¿Hay solapamiento entre clases?

- Puede existir un leve solapamiento en los bordes de las bandas de frecuencia, pero en general las clases están bien diferenciadas y son separables.

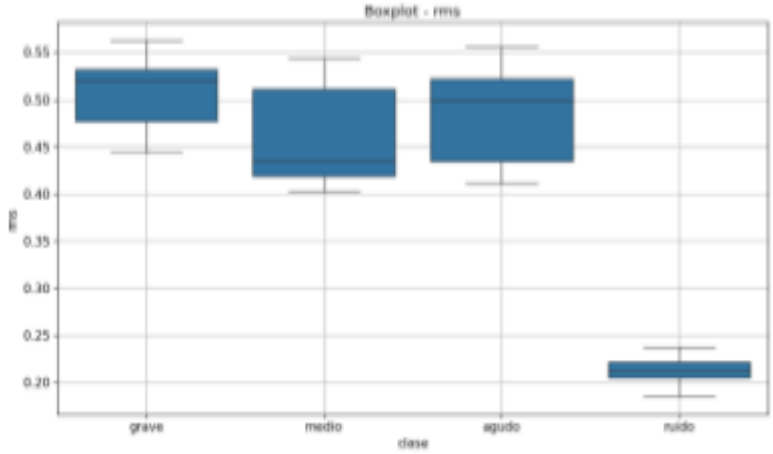
Boxplot - rms
rms
clase
grave
medio
agudo
ruido

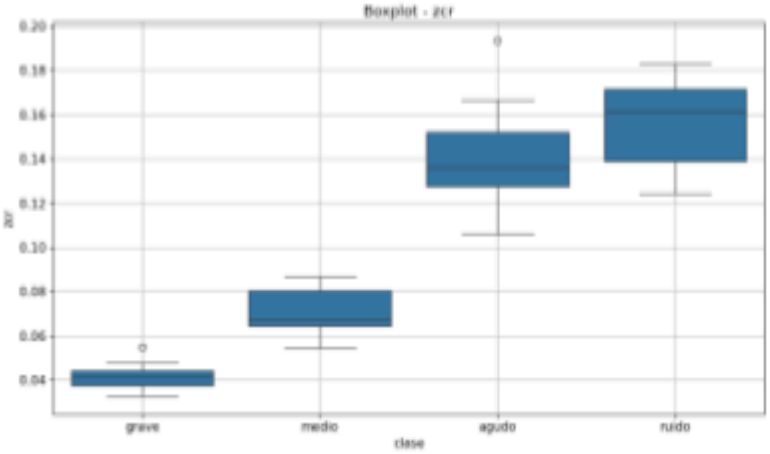
Boxplot - zcr
zcr
clase
grave
medio
agudo
ruido

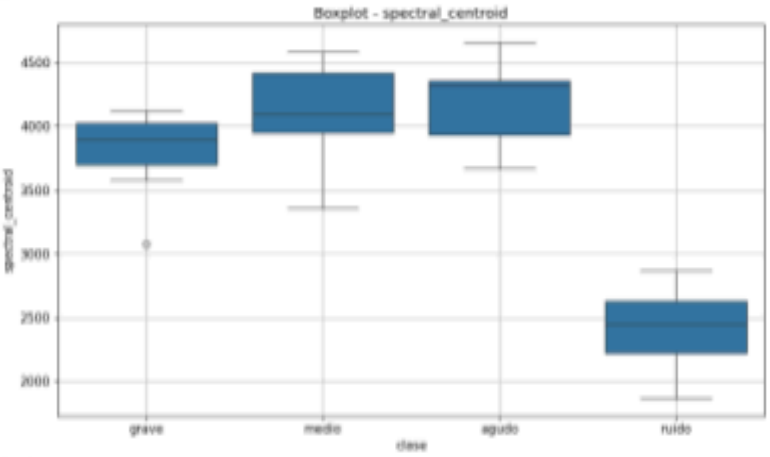
Boxplot - spectral_centroid
spectral_centroid
clase
grave
medio
agudo
ruido

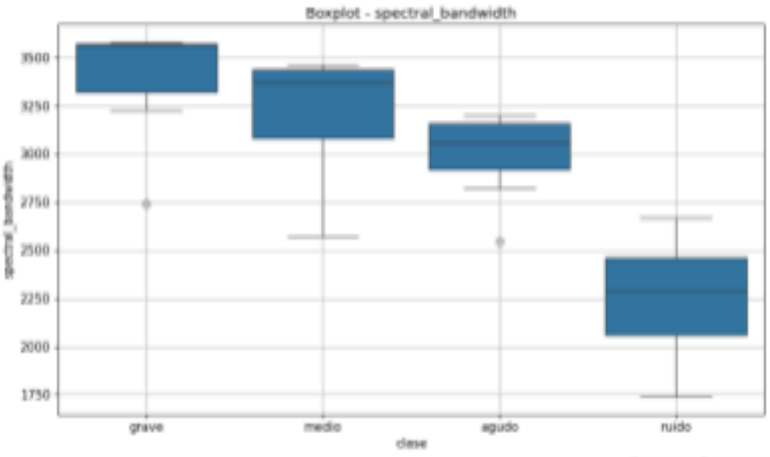
Boxplot - spectral_bandwidth
spectral_bandwidth
clase
grave
medio
agudo
ruido

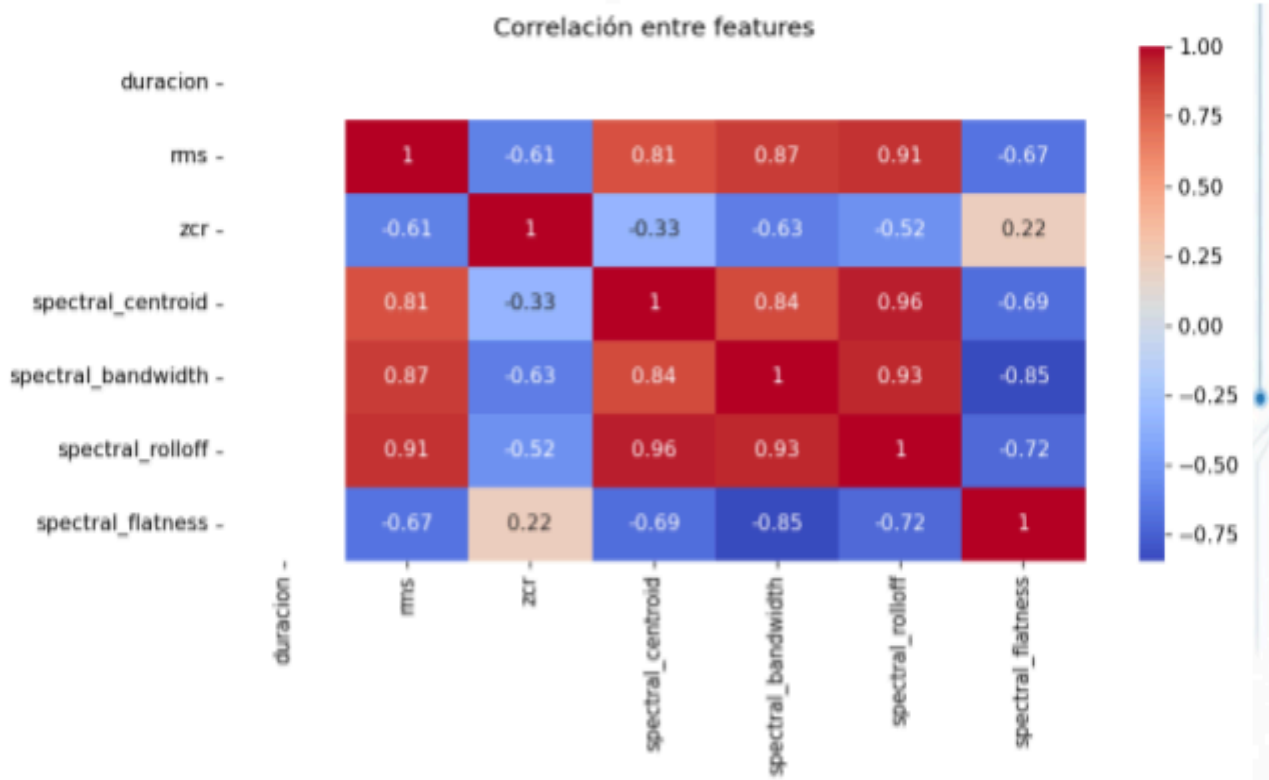
Correlación entre features
duracion
rms
zcr
spectral_centroid
spectral_bandwidth
spectral_rolloff
spectral_flatness
1 -0.61 0.81 0.87 0.91 -0.67
-0.61 1 -0.33 -0.63 -0.52 0.22
0.81 -0.33 1 0.84 0.96 -0.69
0.87 -0.63 0.84 1 0.93 -0.85
0.91 -0.52 0.96 0.93 1 -0.72
-0.67 0.22 -0.69 -0.85 -0.72 1
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75

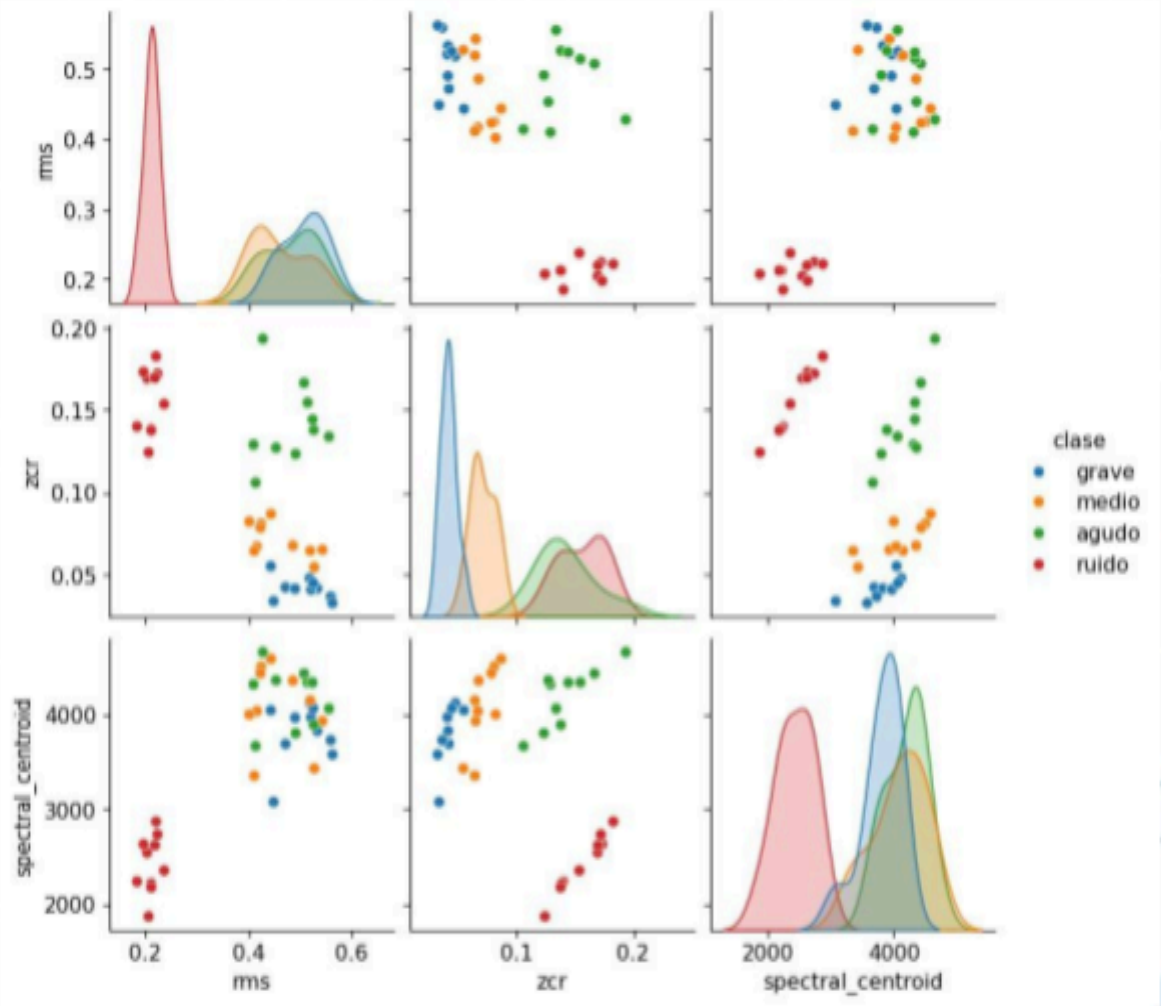
rms
zcr
spectral_centroid
clase
grave
medio
agudo
ruido

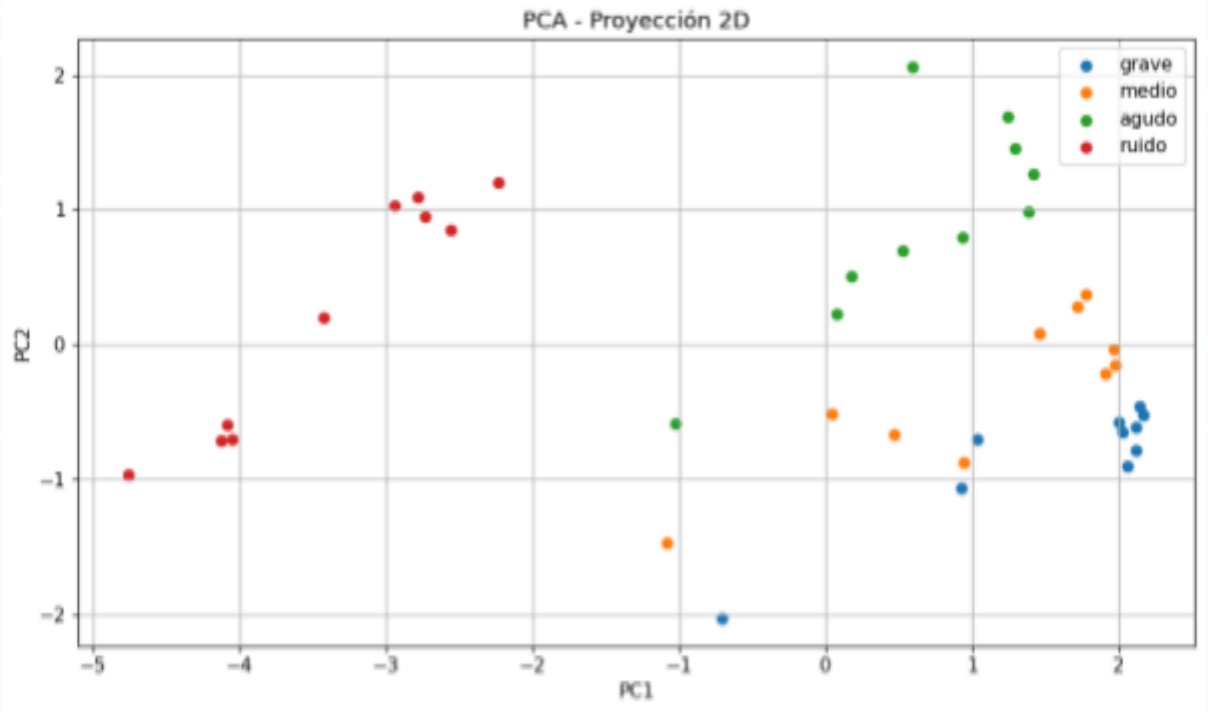
PCA - Proyección 2D
grave
medio
agudo
ruido
PC1
PC2

Conclusiones sobre separabilidad

- Las features extraídas permiten diferenciar las clases de manera efectiva.
- El centroid y el bandwidth son altamente discriminativos, ya que reflejan el contenido frecuencial.
- La ZCR ayuda a diferenciar señales de alta frecuencia (agudos y ruido).
- Se observan algunas correlaciones altas entre features espectrales, indicando posible redundancia.
- El PCA muestra una separación clara entre clases, especialmente entre ruido y señales armónicas.
- En general, las clases son separables en el espacio de características, lo que indica que el dataset es adecuado para tareas de clasificación

PARTE 3: ANÁLISIS E INTERPRETACIÓN

Informe Técnico

1. Introducción

El presente trabajo tuvo como objetivo aplicar conceptos fundamentales del procesamiento digital de señales de audio, integrando aspectos teóricos y prácticos relacionados con muestreo, cuantización, aliasing, preprocesamiento y análisis exploratorio de señales. Se buscó comprender cómo preparar y analizar datos de audio para futuras aplicaciones de clasificación mediante técnicas de aprendizaje automático.

Para ello se trabajó con un dataset sintético compuesto por 40 muestras de audio distribuidas en cuatro clases: grave, medio, agudo y ruido, con diez muestras por categoría. Las señales fueron generadas con frecuencias representativas para cada clase, incorporando además variabilidad en amplitud, duración y ruido de fondo controlado para simular condiciones similares a un entorno real.

La metodología aplicada incluyó varias etapas. En primer lugar se generaron y analizaron señales sintéticas para estudiar efectos de muestreo y cuantización. Luego se construyó el dataset y se aplicó un pipeline completo de preprocessing que incluyó recorte de silencios, normalización y ajuste de duración. Posteriormente se realizó un análisis exploratorio mediante Transformada de Fourier (FFT), extracción de features acústicas y análisis estadístico, incluyendo reducción de dimensionalidad mediante PCA para evaluar separabilidad entre clases.

Se puede consultar el código en el siguiente link a Google Colab.

2. Resultados del Preprocessing

Durante el análisis inicial de los datos crudos se detectaron diversos problemas característicos en señales de audio: variabilidad en la duración de las muestras, amplitudes inconsistentes entre registros, presencia de silencios iniciales y finales, y ruido de fondo incorporado artificialmente para simular condiciones no controladas.

Para resolver estas problemáticas se aplicaron distintas transformaciones. En primer lugar se utilizó trimming para eliminar silencios no informativos, mejorando la eficiencia del análisis. Luego se realizó normalización de amplitud para llevar todas las señales a una escala comparable. También se ajustó la duración de las muestras a un valor fijo de dos segundos mediante padding o recorte, con el fin de homogeneizar el dataset para tareas posteriores de extracción de características.

Estas transformaciones tuvieron un impacto cuantitativo significativo. Se observó una reducción promedio de duración en señales con silencios prolongados, una uniformidad mayor en los niveles de amplitud máxima y una mejora en la consistencia general del

conjunto de datos. El preprocesamiento permitió reducir variabilidad no deseada y resaltar la información acústica relevante de cada clase

3. Análisis Exploratorio

El análisis espectral permitió identificar características distintivas en cada clase. Las señales graves mostraron concentración energética en bajas frecuencias, principalmente entre 200 y 400 Hz. Las señales medias presentaron componentes dominantes entre 600 y 1000 Hz. Las señales agudas concentraron energía en frecuencias superiores, entre 1500 y 2500 Hz. Por su parte, la clase ruido exhibió una distribución espectral mucho más dispersa y menos estructurada.

Entre las features extraídas, las más discriminatorias fueron spectral centroid, spectral bandwidth, zero crossing rate y spectral rolloff. El spectral centroid permitió diferenciar claramente clases según contenido frecuencial dominante. El bandwidth reflejó dispersión espectral y ayudó especialmente a distinguir señales de ruido. La tasa de cruces por cero resultó útil para separar señales periódicas de señales ruidosas.

En el análisis de correlación se detectaron relaciones altas entre spectral centroid y rolloff, así como entre centroid y bandwidth, indicando cierta redundancia parcial entre variables espectrales. Esto sugiere que algunas features podrían reducirse sin pérdida significativa de información en modelos predictivos.

La aplicación de PCA permitió visualizar una separación clara entre las clases, especialmente entre grave, agudo y ruido. Aunque existió cierto solapamiento parcial entre algunas muestras intermedias, la proyección en dos componentes principales mostró una estructura suficientemente separable, indicando que el dataset presenta buen potencial para tareas de clasificación supervisada.

4. Conclusiones y Recomendaciones

A partir de los resultados obtenidos puede concluirse que el dataset es adecuado para tareas iniciales de clasificación, ya que presenta patrones diferenciables tanto en dominio temporal como frecuencial. El preprocesamiento mejoró la calidad del conjunto de datos y las features extraídas mostraron capacidad discriminativa relevante.

Como mejoras futuras se propone ampliar la cantidad de muestras por clase, incorporar mayor variabilidad intra-clase, agregar grabaciones reales en distintos entornos acústicos y considerar técnicas adicionales de reducción de ruido. También sería recomendable incluir nuevas clases y variaciones de locutores para aumentar robustez.

Para un modelo de machine learning se recomendaría utilizar principalmente spectral centroid, bandwidth, rolloff, zero crossing rate y complementar con coeficientes MFCC, dado que son ampliamente utilizados en reconocimiento de voz y clasificación de audio por su poder representativo

Reflexión Crítica

a) Explicación del análisis espectral mediante analogía

El análisis espectral de audio puede explicarse como si una canción fuera una receta y quisiéramos saber de qué ingredientes está hecha. Aunque escuchamos el sonido como un todo, en realidad está compuesto por muchas frecuencias mezcladas. La Transformada de Fourier funciona como una herramienta que separa esos ingredientes y nos muestra cuánto hay de cada uno. De ese modo es posible identificar tonos graves, agudos, armónicos o ruido dentro de una señal.

b) Concepto más difícil de comprender

El concepto que resultó más complejo fue aliasing, especialmente entender cómo una frecuencia puede “disfrazarse” como otra por un muestreo insuficiente. La dificultad se superó mediante ejemplos visuales y simulaciones prácticas, observando cómo diferentes frecuencias de muestreo modificaban la señal y generaban distorsiones. Verlo aplicado facilitó comprender un concepto inicialmente abstracto.

c) Recomendaciones para recolección de datos en asistentes de voz

Si trabajaramos en un equipo de desarrollo de asistentes de voz recomendaríamos recolectar datos en múltiples condiciones acústicas, con distintos micrófonos, locutores, velocidades de habla y niveles de ruido ambiente. También sería importante balancear clases, estandarizar calidad mínima de grabación, etiquetar correctamente y aplicar validación de calidad antes de incorporar datos al entrenamiento.

d) Aplicación en proyecto final o contexto laboral

Estos conocimientos pueden aplicarse en proyectos relacionados con clasificación de audio, reconocimiento de comandos por voz, detección de patrones sonoros o asistentes conversacionales. En un contexto laboral serían útiles para tareas de preparación de datos, ingeniería de features, control de calidad de señales y diseño de pipelines de procesamiento para modelos de inteligencia artificial basados en audio. También aportan fundamentos para interpretar mejor los datos antes del modelado, aspecto esencial en ciencia de datos.

Link al repositorio grupal
Link al repositorio de Maciel Barbero
Link al repositorio de Jonathan Molina
Link al repositorio de Mauricio Molina